

NAMA : Muhammad Verri Andika Pratama
NIM : 231240001452
KELAS : DC

JUDUL	Komparasi Algoritma Random Forest, XGBoost, dan CatBoost Menggunakan Borderline-SMOTE Berbasis Explainable AI (SHAP) untuk Deteksi Dini Risiko Dropout Mahasiswa
RUMUSAN MASALAH	Bagaimana efektivitas penerapan teknik penyeimbangan data Borderline-SMOTE dalam meningkatkan sensitivitas (recall) deteksi kelas minoritas mahasiswa yang berisiko dropout pada dataset akademik perguruan tinggi, serta seberapa besar perbedaan performa komparatif antara algoritma Random Forest, XGBoost, dan CatBoost pada data bertipe campuran numerik dan kategorikal, sekaligus bagaimana implementasi Explainable AI menggunakan SHAP (SHapley Additive exPlanations) mampu memberikan transparansi faktor risiko secara global maupun individual guna mendukung pengambilan keputusan intervensi akademik yang preventif dan terukur?
LATAR BELAKANG	Perkembangan teknologi informasi mendorong transformasi tata kelola pendidikan tinggi melalui pemanfaatan Educational Data Mining (EDM) guna meningkatkan mutu institusi dan efisiensi studi mahasiswa. Fenomena putus kuliah (dropout) dan keterlambatan penyelesaian masa studi masih menjadi persoalan krusial yang berdampak langsung pada indikator akreditasi perguruan tinggi serta menimbulkan kerugian materiil dan waktu bagi mahasiswa maupun keluarga. Berdasarkan observasi di lingkungan akademik, evaluasi dan pendampingan terhadap mahasiswa bermasalah umumnya baru dilakukan secara intensif pada semester akhir saat batas masa studi hampir habis, sehingga intervensi pembimbing akademik sering kali terlambat (Villar & de Andrade, 2024; Bettahi et al., 2025). Padahal, riwayat capaian akademik pada tahun pertama perkuliahan—seperti rasio kelulusan SKS semester awal, IPK, dan kedisiplinan administratif pembayaran uang kuliah—merupakan indikator penentu yang sangat kuat untuk memproyeksikan potensi keberhasilan studi mahasiswa sejak dini (Albugami et al., 2026; Ridwan & Priyatno, 2024). Namun demikian, pembangunan sistem peringatan dini (Early Warning System) berbasis machine learning menghadapi tantangan metodologis yang signifikan. Tantangan pertama adalah ketimpangan data kelas (class imbalance), di mana jumlah mahasiswa dropout secara alami jauh lebih sedikit dibandingkan mahasiswa yang berhasil lulus. Penggunaan algoritma klasifikasi standar tanpa penanganan ketidakseimbangan kelas

	menghasilkan model yang mengalami bias ke kelas mayoritas dengan nilai recall yang rendah pada kasus dropout. Villar dan de Andrade (2024) menerapkan Synthetic Minority Over-sampling Technique (SMOTE) konvensional pada dataset mahasiswa, namun Endahti (2026) membuktikan bahwa SMOTE standar rentan meningkatkan bias keputusan dan menghasilkan sampel sintesis di wilayah noise. Untuk itu, Borderline-SMOTE diperlukan guna memfokuskan pembentukan sampel sintesis secara selektif pada area batas keputusan kritis (danger zone). Selain itu, dataset akademik memiliki karakteristik multidimensi dengan dominasi variabel sosio-ekonomi dan demografi kategorikal. Penelitian oleh Ridwan dan Priyatno (2024) serta Devkishan et al. (2024) baru menguji model tunggal XGBoost atau ensemble voting tanpa membandingkannya dengan CatBoost, yang secara arsitektural dirancang khusus untuk memproses fitur kategorikal tanpa menimbulkan target leakage. Tantangan kedua adalah karakteristik model ensemble yang berstatus kotak hitam (black-box model). Model dengan tingkat akurasi tinggi tidak akan dapat diimplementasikan secara optimal jika pihak Dosen Pembimbing Akademik (DPA) dan pengelola program studi tidak dapat memahami variabel apa yang menjadi pemicu ancaman putus kuliah pada setiap individu mahasiswa. Kajian terkini oleh Bettahi et al. (2025), Albugami et al. (2026), serta Nti dan Ramanayake (2026) menegaskan urgensi penerapan kerangka kerja Explainable AI (XAI) berbasis SHAP (SHapley Additive exPlanations) untuk menyajikan penjelasan atribusi fitur secara transparan dan akuntabel. Oleh karena itu, penelitian ini bertujuan mengkomparasikan performa algoritma Random Forest, XGBoost, dan CatBoost dengan penanganan Borderline-SMOTE, serta mengintegrasikan metode SHAP guna menghasilkan sistem deteksi dini risiko dropout mahasiswa yang tidak hanya akurat dan peka terhadap kelas minoritas, tetapi juga dapat diinterpretasikan secara transparan untuk mendukung intervensi akademik yang presisi di perguruan tinggi.
TINJAUAN PUSTAKA (STATE OF THE ART)	1. Villar dan de Andrade (2024) membandingkan algoritma supervised machine learning (Random Forest, SVM, Naive Bayes, Decision Tree) menggunakan SMOTE standar pada dataset mahasiswa UCI (ID: 697) dengan 4.424 data dan 36 fitur. Penelitian membuktikan SMOTE meningkatkan recall pendeteksian mahasiswa berisiko dropout, namun SMOTE konvensional masih memiliki kelemahan mendasar karena menyintesis sampel tanpa memperhitungkan batas keputusan (decision boundary) serta model masih bersifat black-box. 2. Ridwan dan Priyatno (2024) menerapkan algoritma XGBoost Classifier tunggal pada dataset akademik mahasiswa UCI untuk memprediksi risiko dropout dan keberhasilan studi berdasarkan data semester awal. Hasil

menunjukkan pemisahan kelas yang baik pada data tabular akademik, namun penelitian ini belum menguji penanganan ketidakseimbangan kelas berbasis batas keputusan, belum memkomparasikan dengan model CatBoost yang adaptif terhadap fitur kategorikal, serta belum mengevaluasi trade-off kurva PR-AUC.

3. Nti dan Ramanayake (2026) merancang kerangka kerja Explainable Machine Learning menggunakan model ensemble gradient boosting yang dipadukan dengan SHAP dan LIME untuk deteksi dini risiko dropout mahasiswa. Penelitian ini membuktikan bahwa transparansi atribusi fitur sangat esensial bagi pengambil kebijakan kampus dalam merumuskan intervensi personal yang tepat sasaran, meskipun belum membedah optimasi penanganan data tidak seimbang di tingkat data pre-processing.

4. Bettahi, Belouadha, dan Harroud (2025) membangun pipeline modular machine learning terstandarisasi berbasis tree ensemble dan SHAP untuk prediksi retensi mahasiswa di perguruan tinggi. Penelitian ini menunjukkan bahwa integrasi XAI menjamin keterulangan (reproducibility) pipeline dan akuntabilitas evaluasi faktor risiko akademik, namun belum menyajikan uji komparatif mendalam terhadap arsitektur CatBoost pada variabel sosio-ekonomi berskala besar.

5. Albugami, Wali, dan Almagrabi (2026) menganalisis prediksi dropout mahasiswa menggunakan Random Forest, Gradient Boosting, XGBoost, dan SHAP TreeExplainer pada lebih dari 5.000 data historis akademik. Hasil membuktikan bahwa capaian akademik semester awal dan status beasiswa/ekonomi merupakan pembeda utama antara mahasiswa bertahan vs dropout, namun penelitian tidak meneliti secara mendalam optimasi penanganan ketidakseimbangan kelas di tingkat resampling adaptif.

6. Devkishan, Singh, dan Bharti (2024) mengimplementasikan teknik ensemble learning (Voting Ensemble, Bagging, Gradient Boosting) untuk memprediksi keberhasilan akademik mahasiswa pada dataset 4.424 baris. Hasil evaluasi membuktikan model ensemble secara konsisten mengungguli model pohon tunggal konvensional, namun evaluasi hanya berfokus pada metrik akurasi global tanpa modul penjelasan individual bagi dosen pembimbing akademik.

7. Endahti (2026) menganalisis pengaruh teknik oversampling SMOTE terhadap bias keputusan model machine learning pada prediksi dropout mahasiswa di perguruan tinggi Indonesia. Penelitian menemukan bahwa SMOTE standar dapat mengurangi bias kelas mayoritas namun rentan menghasilkan False Positive jika batas kelas (borderline) tidak diperhatikan, sehingga menegaskan perlunya teknik resampling adaptif berbasis batas keputusan (borderline-aware).

REFERENSI / DAFTAR PUSTAKA	Albugami, S., Wali, A., & Almagrabi, H. (2026). Predicting student dropout in Saudi Universities using machine learning and explainable AI. <i>PeerJ Computer Science</i>, 12, e3490. https://doi.org/10.7717/peerj-cs.3490 Bettahi, A., Belouadha, F.-Z., & Harroud, H. (2025). A Modular and Explainable Machine Learning Pipeline for Student Dropout Prediction in Higher Education. <i>Algorithms</i>, 18(10), 662. https://doi.org/10.3390/a18100662 Devkishan, T. S., Singh, S. K., & Bharti, A. K. (2024). Implementation of Machine Learning and Ensemble Learning Techniques to Proactively Predict Students' Academic Success in the Realm of Higher Education. <i>2024 4th International Conference on Technological Advancements in Computational Sciences (ICTACS)</i>, IEEE Xplore, 1–6. https://doi.org/10.1109/ictacs62700.2024.10840530 Endahti, J. L. (2026). Analisis Pengaruh SMOTE Terhadap Bias Keputusan Model Machine Learning pada Prediksi Dropout Mahasiswa. <i>Rabit : Jurnal Teknologi dan Sistem Informasi Univrab</i>, 11(2), 210–221. https://doi.org/10.36341/rabit.v11i2.8275 Nti, I. K., & Ramanayake, S. (2026). Explainable machine learning for student dropout prediction and tailored interventions in online personalized education. <i>Discover Artificial Intelligence</i>, 6(1), 1016. https://doi.org/10.1007/s44163-026-01016-6 Ridwan, A., & Priyatno, A. M. (2024). Predict Students' Dropout and Academic Success with XGBoost. <i>Journal of Education and Computer Applications (JECA)</i>, 1(2), 78–86. https://doi.org/10.69693/jeca.v1i2.13 Villar, A., & de Andrade, C. R. V. (2024). Supervised machine learning algorithms for predicting student dropout and academic success: a comparative study. <i>Discover Artificial Intelligence</i>, 4(1), 79. https://doi.org/10.1007/s44163-023-00079-z
---	---